Análisis de parámetros ambientales para la predicción de días lluviosos en Australia

Diplomado de Ciencia de datos: Proyecto Integrador

José Edgar Hernández Cancino Estrada

Febrero, 2021

Resumen

En este documento se analiza un conjunto de datos correspondientes a mediciones hechas de manera automática por la Oficina de Meteorología en Australia. Los datos corresponden a un periodo de casi 10 años, de finales de 2008 a mediados de 2017, donde se detallan condiciones ambientales como temperatura, precipitación y vientos.
Con esta información, el objetivo de éste documento, es desarrollar un modelo de aprendizaje automático de clasificación que permita predecir si dadas cieras mediciones meteorológicas en un día, el día siguiente se percibirá lluvia o no.

1. Introducción al problema

Los datos se obtuvieron de la plataforma Kaggle, en un *dataset* llamado "*Rain in Australia*". Los datos corresponden a observaciones meteorológicas diarias tomadas en distintos puntos de Australia, y una variable objetivo a predecir, que indica ante dadas ciertas mediciones, el día siguiente fue un día que percibió 1mm de lluvia o más. El conjunto de datos ha sido recopilado y publicado por la Oficina de Meteorologia (*Bureau of Meteorology*) del gobierno Australiano. La referencia tanto al sitio de Kaggle como a la publicación original de los datos se encontrarán en la sección de referencias, al final del documento.
En el sitio se describe la naturaleza de los datos, y se hace una aclaración importante a considerar: Hay ocasiones en que las temperaturas máximas y mínimas, medición de precipiación o evaporación faltan, en estos casos el siguiente valor que encontramos, podría contener mediciones acumuladas de varios días. Esto es por naturaleza del sistema automático, y por esta razón se recomienda tener cuidado con las variables mencionadas.

2. Exploración inicial de los datos

El conjunto de datos original consiste en un archivo *csv* con 23 columnas y $145,560$ registros. Las columnas junto con sus unidades se presenan a continuación:

- Fecha (formato aaaa-mm-dd)
- Ubicación del punto de observación

- Temperatura mínima (grados Celsius)
- Temperatura máxima (grados Celsius)
- Precipitación (milímetros)
- Evaporación (milímetros)
- Horas de luz solar (horas)
- Dirección de la máxima ráfaga de viento (16 puntos del compás)
- Velocidad de la máxima ráfaga de viento (kilómetros por hora)
- Dirección del viento a las 9am y a las 3pm (puntos del comás)
- Velocidad del viento a las 9am y a las 3pm (kilómetros por hora)
- Humedad relativa a las 9am y a las 3pm (porcentaje)
- Presión atmosférica a las 9am y a las 3pm (hectopascales)
- Fracción del cielo con nubes a las 9am y a las 3pm (octavos)
- Temperatura a las 9am y a las 3pm (grados Celsius)
- Llovió el día del registro (variable binaria)
- Llovió el día siguiente (variable binaria)

2.1. Variables redundantes

Para evitar redundancia y la famosa maldición de la dimensionalidad, antes de realizar pruebas para la selección de variables, se realizó una *matriz de correlación* entre las variables numéricas, para identificar y eliminar posibles variables redundantes:

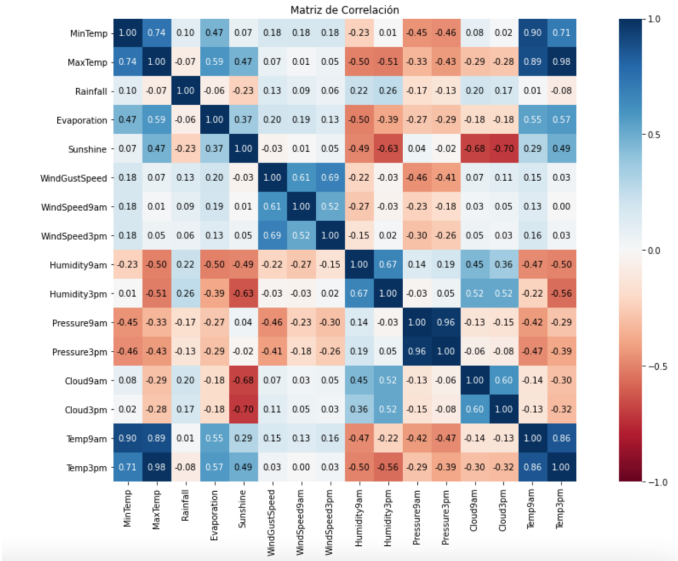

De esta forma, podemos apreciar algunas relaciones altas, como en **MaxTemp** y **Temp3pm** con 0,98 o **MaxTemp** y **Pressure9am** y **Pressure3pm** con 0,96.
Las variables con una correlación mayor o igual a 0.90 serán tratadas. Por esta razón, las columnas **Temp9am**, **Temp3pm** se eliminaron, y **Pressure9am** y **Pressure3pm** al tener una correlación muy alta, se promediaron y se mantuvo su información dentro de la variable **DayAvPressure**.
De igual modo, se planteó la posibilidad de extraer información de las fluctuaciones de temperatura a lo largo del día, utilizando la diferencia entre la temperatura por las mañanas y en la tarde, pero por motivo de mantener un modelo simple, esta estrategia no se llevó a cabo.

2.2. Valores faltantes

El primer paso realizado dentro de la exploración de datos, fue la identificación de valores faltantes.
Recordemos que originalmente, el conjunto tiene 145,460 registros. Al correr la línea *dataRaw.isnull().sum()* en Python, donde *dataRaw* es el *Pandas Dataframe* con los datos originales, poemos observar que hay algunas variables que presentan una cantidad significativa de datos faltantes, y a su vez representan un porcentaje significativo de la cantidad de total de registros. Esto está detallado en la siguiente tabla:

Variable	Datos Faltantes	Porcentaje del Total
Evaporation	62790	43.16 %
Sunshine	69835	48.01 %
Cloud9am	55888	38.42 %
Cloud3pm	59358	40.81 %

Esto es claramente poco conveniente de ignorar, y al ser un porcentaje tan grande, probablemente no sea una buena idea rellenar los datos con una medida de tendencia, por lo que se pensó en dos posibles estrategias para enfrentar el problema:

1. Eliminar los registros donde estas columnas presenten datos faltantes.
2. Eliminar las columnas de dichas variables y realizar el modelo con un mayor número de registros.

Ambas estrategias presentan ventajas y desventajas. Eliminar los registros que no tienen estas columnas resultaría en la pérdida del 61 % de los registros. Sin embargo, por la naturaleza del problema, el nivel de evaporación, y presencia de las nubes pudieran ser factores importantes o determinantes en la percepción de precipitaciones. De cualquier modo, para no perder una gran cantidad de datos, se optó por omitir estas dos columnas. Aún eliminándolas, podemos encontrar estas ausencias en casi todas las columnas (incluyendo la variable objetivo), aunque en mucho menor medida de las anteriormente mencionadas. Por esa razón se procedió a eliminar aquellos registros, perdiendo únicamente el 22.4 % de los registros.

3. Preparación de los datos para la construcción del modelo

3.1. Extracción de características

El siguiente paso fue la extracción de características, conversión de variables *Yes / No* a binarias 1/0, y la utilización de *one-hot ecoding* para algunas carcterísticas cualitativas.

Como ya se mencionó, a partir de las dos mediciones de presión durante el día, se obtuvo una medida de presión promedio de cada día. Además de ésta, otra característica extraida fue la estación del año en la que se encuentra el registro. Para esto, se utilizó el mes del año y mediante la línea: $df['Season'] = (pd.DatetimeIndex(df.Date).month)\,\%12//3 + 1$, se registró la columna **Season**, obteniendo valores de 1 a 4, para denotar las estaciones de invierno a otoño. La estrategia utilizada es la conocida como *integer* o *label encoding*.
La columnas de **RainToday** y **RainTomorrow** a su vez, cuenta únicamente con valores de sí o no, por lo que se cambiaron sus valores a $si = 0$ y $no = 1$.
Hasta ese momento, contamos con 16 columnas de características, donde 15 son las variables a medir, y en las cuales tenemos:

- 9 Numéricas
- 5 Categóricas
- 1 Binaria

Después de esto, el siguiente paso fue la creación de *dummy variables*, producto del *one-hot encoding*, aplicadas a las variables categóricas correspondientes a la dirección del viento y de las ráfagas de viento.
Es importante mencionar que a pesar de que sólo hay 4 columnas a las que aplicaremos este proceso, los números de valores únicos de que presentan son altos: **Location** tiene 44 y las de dirección del viento 16. Realizar este proceso aumentó mucho la dimensionalidad de nuestro modelo, pero ha sido necesario para contemplar las variables categóricas no ordinales.

3.2. Normalización y reescalamiento

El siguiente paso ha sido la normalización de las magnitudes de las variables.
Aquí se presentan los histogramas de las variables numéricas.

```
In [76]: df.hist(column=numericas, figsize=[18,12], bins=200)
         plt.suptitle("Histograms")
         plt.show()
```

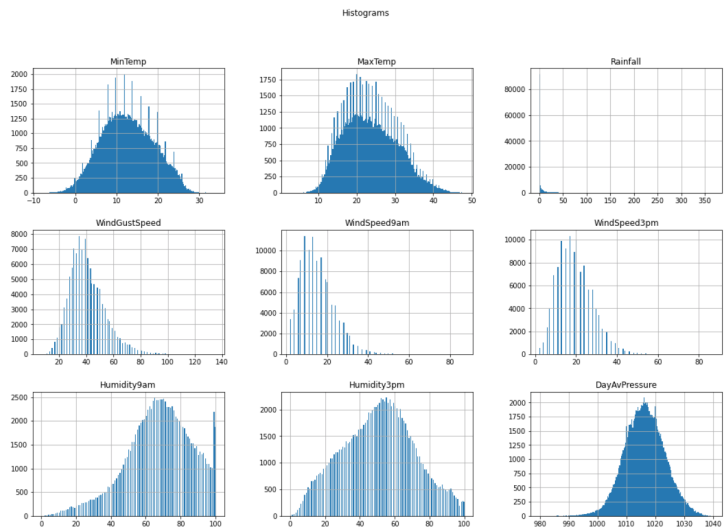

Podemos observar que casi todas las variables tienen curvas Gaussianas o cuasi-Gaussianas, con ciertos pesos a la izquierda o derecha. Para corregir esto, y aproximar las variables a una curva gaussiana ideal, se llevarán a cabo distintas estrategias de normalización, y se aplicarán técnicas de reescalamiento para mantener todas las variables en una escala similar. Sin embargo, antes de hacer esto, tenemos que considerar la calidad de los datos, pues es claro que en las distintas curvas, y sobre todo en la que corresponde a la variable **RainFall**, tenemos presencia de *Outliers* que nos dificultan apreciar las gráficas, y que pudieran representar ruido en nuestro modelo. Para esto, se utilizará un método estadístico para detectarlos y corregirlos, quedadonos únicamente con aquellos valores que estén a lo más a 2 veces la desviación estándar del medio para cada metrica.

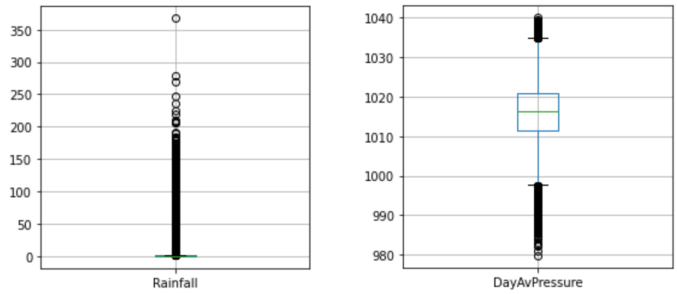

Se aplicó una normalización utilizando el escalamiento estándard (*StandardScaler()*) para las distribuciones que se aproximaban más a una campana Gaussiana, siendo estas: **MinTemp**, **MaxTemp**, **WindGustSpeed**, **"WindSpeed9am**, **WindSpeed3pm** y **Humidity3pm**. Como **Humidity9am** y **DayAvPressure** tienen una distribución conun peso claro hacia la izquierda, se utilizó el metodo *RobustScaler()*. Por último, se utilizó una transformación logarítmica para la variable **Rainfall**, inputando 0 como constante en los casos que el valor de la variable fuera 0.
Estas son las gráficas una vez habiendo normalizado los datos:

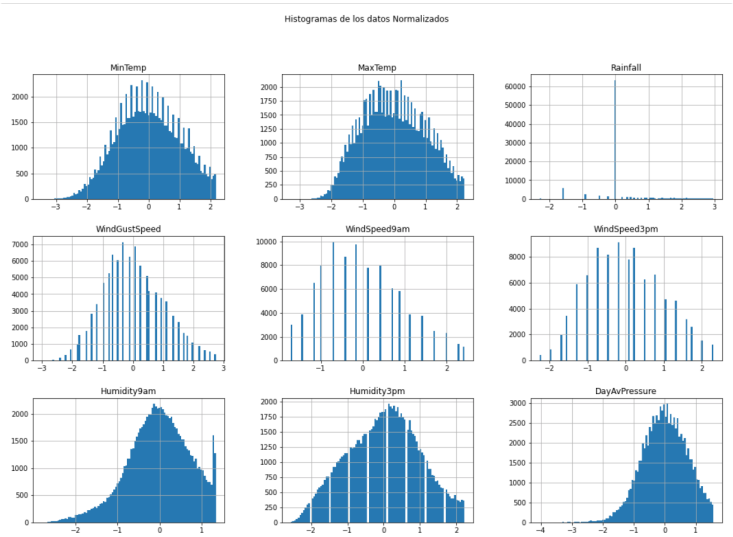

3.3. Selección de características

Ahora que tenemos los datos normalizados y hemos eliminado los *outliers*, contamos con un *dataframe* de 92413 registros y 104 columnas (gran número de columnas debido a las variables *dummy* utilizadas). El paso siguiente es la selección de las características más relevantes, que utilizaremos para entranar el modelo de predicción.
Es preciso recordar que estamos buscando predecir una clasificación; debemos decidir si basadas las características de el día de hoy, mañana será o no un día con lluvia. Y tenemos variables numéricas y categóricas (que se han coificado utilizando *one-hot encoding* jugando un papel en la decisión.
Para la selección de características, se utilizó la estrategia ANOVA, pues funciona para tomar las mejores caracteríticas tanto numéricas como categóricas cuando la variable a predecir es categórica.

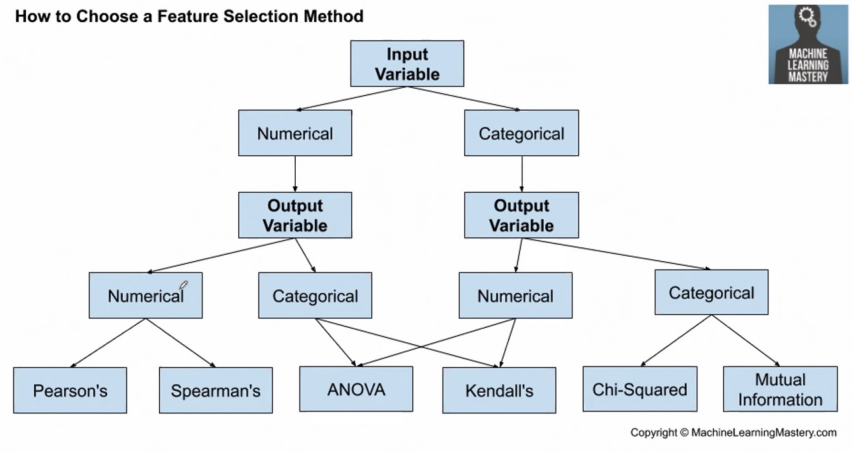

Tras correr el algoritmo ANOVA con el método *SelectKBest(*, pudo apreciarse que había 7 variables con un grado de importancia significaitvo, muy diferente al resto de las características. Por este motivo, se eligió $k = 7$ para iniciar el entrenamiento del modelo.

4. Creación de un modelo de aprendizaje automático para la clasificación de las variables objetivo

Como la variable a predecir es una clasificación binaria, se probaron los distintos algoritmos vistos en clase para decidir qué modelo pudiera ser el más apropiado. Los modelos (para clasificación) fueron los siguientes:

- KNN
- Regresión Logística
- Árbol de Decisión
- *Random Forest*

Cada modelo, utilizó un *cross-validation* de 10 repeticiones.

4.1. Evaluación del modelo

Analizando el desempeño de cada modelo (lo cual puede ser apreciado en la *Jupyter Notebook* que se entregó junto al documento), obtenemos la siguiente tabla:

	KNN	Logistic Regression	Decision Tree	Random Forest
Accuracy	79.38 %	83.30 %	85.49 %	85.90 %
Precision	43.63 %	53.73 %	68.03 %	70.74 %
Recall	43.87 %	62.02 %	37.86 %	38.93 %

Podemos observar en la columna de **accuracy**, que todos los modelos tienen una métrica alta, alrededor de un 80 %. La característica **precision** tiene valore significantemente mas bajos en algunos modelos, y se destaca sobre todo en el *Random Forest* con un 70.74 %. En **Recall**, tenemos las métricas más bajas, y es *Logisstic Regression* la que tiene la mejor medida, con un 62.02 %. Si recordamos que:

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

Y consideramos que en la columna de la variable objetivo, tenemos muchísimas más columnas indicando que no llovió ante que sí llovió (lo que significa que si el modelo no fuera bueno, podría detectar condiciones negativas en muchos casos y aún así parecer que fuciona), podemos concluir que la métrica que nos sirve más para ponderar la decisión de qué modelo es mejor, es **Recall**, puesto que esta se centra en qué tantos de los días lluviosos fueron predichos correctamente.
Por este motivo, podemos determinar al modelo de **Logisic Regression** como el mejor de los modelos probados, con un *Recall* de 62,02 %.

5. Mejoras potenciales

Las medidas de efectividad del modelo indican una confianza de alrededor de un 62,02.
Para mejorar el desempeño, pudieramos haber seguido otras estrategias, como considerar las columnas eliminadas de evaporación y nubes, sacrificando una gran cantidad de registros en vez de haber eliminado las columnas, o quizás haber hecho modelos distintos para cada ciudad.
Esta última propuesta pudiera haber hecho un mejor modelo, pues cada ciudad tiene diferentes propiedades al estar situadas en diferentes lugares y en cada una de ellas, algunas características como los vientos procedentes de distintas direcciones pudieran tener una importancia más grande a la hora de influir en las precipitaciones. Al hacer esto, para cada ciudad se tendría un modelo específico, y al hacer un test, lo primero sería revisar la ciudad, para utilizar el modelo de predicción adecuado.
Estas son adaptaciones que podrían hacerse en un futuro, para evaluar y mejorar el modelo de predicción, pero estas modificaciones no se hicieron para este proyecto.

6. Referencias

1. Notes to accompany Daily Weather Observations. (2021). Recuperado el 13 de february de 2021, de Bom.gov.au: http://www.bom.gov.au/climate/dwo/IDCJDW0000.shtml

2. Young, J. (2020). Rain in Australia. Recuperado el 13 de febrero de 2021, de Kaggle.com: https://www.kaggle.com/jsphyg/weather-dataset-rattle-package

3. Notas del diplomado de Ciencia de Datos del ITPE.